* Digital Communications *

" Computer "

" Section 1 "

"Information Theory"

SALEH RAMADAN

ال Communication عبارة عن إنك عندى

عند مكان اللى هو سميناه Information

ال Transmitter ، ال Info. دى مش

معلومة عند مكان تانى اللى بنسميه

ال Receiver وعايزين نخلى ال

Receiver يكون عارف المعلومة دى

فمحتاجين نبعتها من ال Transmitter لـ

Receiver

فى ال Communication System عندنا

Two Blocks

مهمين زى ما واضح فالصورة دى.

Communication Systems
Block Diagram

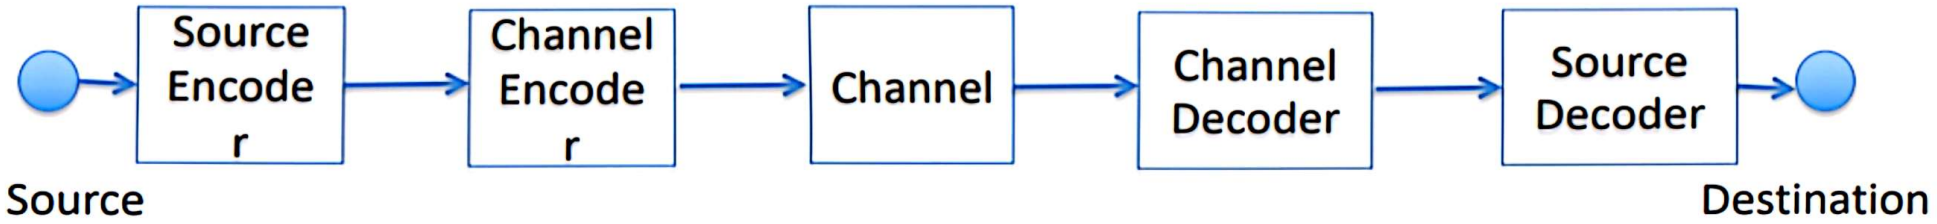

CamScanner

③

ال Source Encoder وهو إن عندى ال

Info اللى عايز ابعتها من ال

عايز اعملها Source لل destination

عايز. عاإننا bits بمجموعات Representation

هنشتغل ← digital communication

ال Source Encoding وظيفته إنه امثل

ال Info بمجموعات bits بس قبل

مابعت ال bits دى على ال channel

ال channel هتسبب Errors لل

bits دى، فبنعمل لل bits دى

Encoding تانى بحيث لما ال bits دى

نوصل عند ال Rx نعرف من ال bits

اللى خفيناها على ال Info اللى طالع

منا ال Source Encoder وال encoding اللى علناه

④

نقدر نـ detect الـ error وتعلك correction

وده اللي هو الـ "Channel EnCoder" ⟵

هيقوم بعليك الـ EnCoding قبل ماتبعت

على الـ Channel.

وطبعاً الـ Source EnCoder والـ Channel EnCoder

هيكون ليهم decoders عند الـ Receiver

بنقول بقى إننا عندنا Two Goals واحنا

بنعمل الـ Two EnCoding دول

وهو إني عايز على قد ماقدر اقلل عدد

الـ bits اللي بتـ represent الـ Source

وفي نفس الوقت محتاج اعمل Maximize

لعدد الـ bits اللي عايز ابعتها على الـ

Channel بـ Zero Errors ، ده معناه

مثلاً أنا دلوقتي عايز اكبر عدد الـ bits

واعلى الـ Rate اللي بيت بيا واستغل

⑤

ال B.W استغلال كويس - وفي نفس الوقت

عايز اكون بعت أكتر من Source ، ومحلش

Block لواحد منهم ، يعني لو انا

بعت 100 bits على ال Channel ده

ال Max وعندي 10 Sources

لو عندي Source مثلاً ال Info بتاعتك

Represented بـ 60 bit والتاني 40 bit

ساعتها مش هقدر ابعت على ال Channel

غير Two Sources وهعمل Block للباقي

وبالتالي ال Goal بتاعي إني اعمل

Minmize لعدد ال bits اللي بت

Represent ال Source اللي هواعمل

Compression ، فلو نفترض إن خليت كل

ال Sources ← represented بـ 10 bits

ساعتها هقدر ا Serve ال 10 Sources

وبالتالي بيقى ده ال Goal الأول.

1) Number of bits **Produced** Per Sec Should be **Minimized.**

2) Number of bits **Transmitted** Per Sec Should be **Maximized.**

ده معناه إني عايز بدل ماقدر ابعت على ال Channel 100 bits مش عيب 500 bits ، لو اقدرت اكبره واخليه error صاعتها هعمل 50 Sources / Serve .

بيبقى كده فهمنا ال Two Goals ، وال Two Tools اللي هيساعدوني في ده هو ال Source Encoding وال Channel Encoding

والعلم اللي هيدرس ده بنسميه "Information Theory"

بيبقى كده ←

Information Theory

Source Encoding

Channel Encoding

علشان نعرف ال Encoding اللى عملناه كان كويس ولا لأ فبنعرف Metric

تكل Encoding نعرف منه ال Performance بتاع ال Code اللى عاملناه ، فبالنسبة لـ Source Encoding بنعرف كده

"Entropy "H""

ودى بتكون Function of Source يعنى بتتغير حسب ال Source.

⑧ وبالنسبة للـ Channel Encoding بتعرف ↓

"Capacity C"

وده بتكون في الـ Function

Channel.

فبنقول بقى دلوقتى قال Source Encoding

انت عايز تـ Minimize عدد الـ bits

اللى بتـ Represent الـ Source

يعنى عايز تعمل "Compression" فعندنا

نوعين من الـ Compression وهما

"Lossless" ↓

يعنى الـ data

بعد ما عملها

Compression

هقدر استرجعها

تانى من غير

Loss

زى مثلاً فكرة الـ Zipping

للـ Files

"Lossy" ↓

هنا لما اجى استرجع

الـ data هيكون

فى Error بس

ACCTable

زى مثلاً جودة فيديوهات

اليوتيوب ، الجودة

القليلة بتبين ان

(9) عملت Lossy Compression وفيها جيت

استرجعها مش كل التفاصيل بتاعت ال

Image قدرت استرجعها بس ده

acceptable ←

يعني ال Users ← still شايفة ده

وال Compression اللي حصل في

سبيل اني أكتر عدد ال Sources اللي

اعلم Serve.

بنقول بقى إن في ال Source

لو Encoding

عايز اعمل Lossless Compression عمري

ما هلاقي code يعمل represent

لل Source بعدد bits أقل من

ال Entropy "H" بتاعت ال

Source، لو أقل بقى هيحصل

Loss وبالتالي ال H هو

Metric مهم محتاجين نعرفه عند ال Source.

الحاجة التانية إننا بنقول إننا عايزين نـ Maximize عدد الـ bits اللي نقدر نبعته على الـ Channel من غير Errors

واللي هيساعدنا في ده هو الـ

Channel Encoding

فبنقول إني مينفعش الاقي Code يخليني ابعت bits واستلم من غير error أو لو كان عدد الـ bits ده أقل من الـ "C" بتاعت الـ Channel، وبالتالي ده بردو MetriC مهم لازم تكون عارفينه عن الـ Channel

وبالتالي بنعرف ←

Source Encoding: The Minimum Number of bits required to represent a source is The Entropy of Source "H"

ده أقل عدد bits ممكن أوصله وهو
إني امثله بـ "H bits"

Channel Encoding:

The Maximum number of bits, we can transmit error free over channel is The capacity "C" of Channel

زي ما تكلمنا قبل كده إن كل حاجه في ال Communication System بتكون.

Info اللي هتطلع زي ال Random Source منك ال بنعتبرها Random Variable

ال Channel بنعتبرها ←

Probabilistic Mapping between InPut & outPut

من أشهر الـ Models اللي بتوصف الـ Channel هو الـ Behaviour بتاعه

*Binary Symmetric Channel:

وهو إننا فالأغلب بنكون باعتين 0,1 من الـ Tx وهنستقبل عند الـ Rx 0,1

فممكن نـ Model الـ effect اللي هيحصل على الـ Channel على الـ data اللي بنبعتها كده

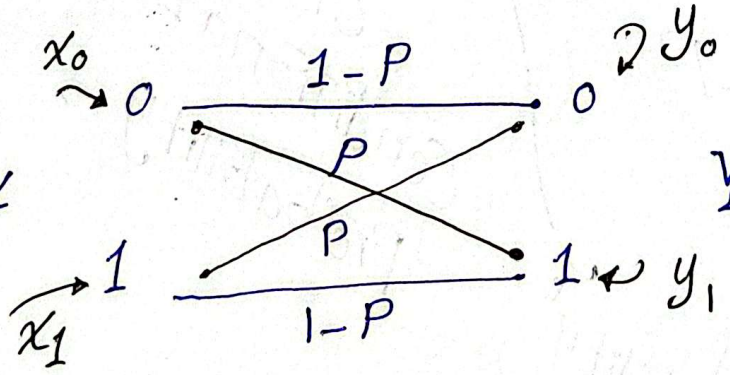

احتمالية إن الـ 0 اللي ابعتت يتقلب لـ 1 عند الـ y هو الـ P اللي بنسميها Pe

Probability of Error

واحتمالية إنى أستلم زى ماهو هتكون

1 مع الـ "1-P" - نفس الكلام

وعشان كده قولنا إن الـ Channel هى

Probabilistic Mapping

بتعرف فى الـ Model عن طريق

الـ Maths بالشكل ده ←

$$P(y_0|x_0) = 1-P$$

$$P(y_0|x_1) = P$$

$$P(y_1|x_1) = 1-P$$

$$P(y_1|x_0) = P$$

بس الـ Model دى الـ Channel بالـ Conditional Probability

"Total Probability"

$$P(y_0) = P(y_0|x_0)P(x_0) + P(y_0|x_1)P(x_1)$$

$$P(y_1) = P(y_1|x_0)P(x_0) + P(y_1|x_1)P(x_1)$$

ممكن بنحط ال Probabilites في Matrix

ونسميها ← "Transition Matrix"

$$P(y|x) = \begin{matrix} \\ x_0 \\ x_1 \end{matrix} \begin{matrix} \begin{matrix} y_0 & \quad y_1 \end{matrix} \\ \begin{bmatrix} P(y_0|x_0) & P(y_1|x_0) \\ P(y_0|x_1) & P(y_1|x_1) \end{bmatrix} \end{matrix}$$

خلينا نفتكر برضو ←

$P(x,y)$ → Joint Probability

~~$P(x)y$~~

$$P(y|x) = \frac{P(x,y)}{P(x)}$$

← $x, y \Rightarrow$ Ind. RVs ولو كان ال

$$P(x,y) = P(x)\,P(y)$$

$$P(y|x) = P(x)$$

→ ودي أسوأ حاجة ممكن تحصل فال Comm. إني اللي بستلمه ميكونش ليه علاقة باللي بعتته فال Pe أعلى حاجة

كده خدنا مقدمات سريعة خلينا نبدأ بالكلام عن ←

* Source Encoding :

بيقولي زي ماقولنا هدفنا إننا نحل Representation

ال Source بأقل عدد bits ممكن وعرفنا Lossless ماهنقدر نسترجعه ويكون

لو كان عدد ال bits أقل من ال "H" ←

وبالتالي محتاجين نتكلم شويه عن ← فالسيكشن ده EntroPy

* EntroPy "H" :

زي ماقولنا إن ال Source هيطلع Random هنعتبرها Random Info ، فال Variable بتاعة ال definition بتاعة ال Random Variable ل EntroPy إنه

بيعبر عنه الـ "Average Uncertainty" بمعنى

لو عندى Source وليه Two values

زى مثلاً الـ Coin وكان الـ Coin

Fair يعنى $P(H) = P(T) = 0.5$

فلما اعمل Flip لـ Coin ، الـ output اللى

طالع إنى اعرف هيكون ايه فال

Uncertainty عاليه ، فبقول إن الـ

Entropy عاليه ، لكن لو هنفترض

إنه كان الـ Coin عبارة عن وش و وش

بس يعنى ← Head

$P(H) = 1$

$P(T) = 0$

لما اعمل Flip لـ Coin هل هيكون

فى أى Uncertainity !؟ الاجابة

لا أنا متأكد 100% إنه هيطلع Head

وبالتالى الـ Entropy هتكون قليلة بـ 0.

أو بتعرف الـ Entropy بإنها مقدار المفاجأة

يعنى إن لو الـ $P(H) = 1$

$P(T) = 0$

فانا لو طلع الـ Tail المفاجأة هتكون كبيرة أوى ممكن نعتبرها Infinite

لإن احتمالية حدوث بـ 0، لكن لو طلع Tail فالمفاجأة هنا بـ 0 مش مستغرب إنه طلع كده.

"المفاجأة" دى ساعات بنسميها Self_Information "I"

يعنى إنما بتغير دلوقتى، لما يكون الـ $P(H)=1$ و الـ $P(T)=0$

(18) فانا عملت ال flip عند ال Tx ، محتاج

ابعت bit لل Rx عشان يعرف اللى

طلع ايه ؟! ، ال Logic بيقول إنه

ال - 0 ، ال Info تعتبر 0 وبالتالى

مش محتاج امثلها بـ bits وابعتها عشان

ال Rx يعرف هى ايه ، هو كده عارفها

قبقول ساعتها إن ال Self Information اللى

همثل بيه ال Bits اللى تعبر عن ال Head

هى 0

لكن بالنسبة لو كان ال P=0 معناها

إن احتمالية حدوث الحاجة دى 0

وبالتالى لو حطيت ال Rx هيحتاج

عدد ∞ من ال bits عشان يقدر يعرف

هى حطيت 0 أو 1 أو يقدر يعمل

decode ، فهما قالوا خلاص عايزين

(19) نحط Maths definition لـ Logic ده

فقالوا لو عندنا Random variable

و ال RV ده ليه discrete values

$\hookrightarrow X = \{x_0, x_1, \dots x_n\}$

فاحنا هنعرف ال Self Information

كل Value ←

$$I(x_i) = -\log(P(x_i))$$

وده فعلاً متماشي مع اللي قولناه ، لإن

دلوقتي لو عندي ال $P(x_i) = 0$

فهيطلع ال I بـ ∞ اللي هو

عدد ال bits (Amount of Info) اللي هو لازم ابعته

يمثل ال Value دي عشان ال Rx

يعرف يعملها decode . ولو كان

$\hookrightarrow P(x_i) = 1 \implies I(x_i) = 0$

(16) مش محتاج ابعت اى Rx لل bits

هو كده كده عارف إن ال Value دى

هتطلع - فالك بقى ال Entropy هى

بتبين عدد ال Average من ال Info

(عدد ال bits) اللى محتاج امثل بيه

ال RV ده و بالتالى هعمل

Average على كل ال Values بتاعت ال RV

$$H = \sum_{i=0}^{n} P(x_i) * I(x_i)$$

أو اللى ممكن تكتبها كده

$$H = \sum_{i} - P(x_i) \log_2 (P(x_i))$$

② علشان احنا عايزين بت

Source ال represent بـ bits يلو

فلو OCTs زى ال bits حاجة غير ال

Base ال هنحط 8.

مثلاً لو عايز بين Entropy ايبقى كده ال

نحسبها ←

$$RV = \{0, 1, 2, 3\}$$
"X"

و ال Prob. هنا Uniform

$$P(x_0) = P(x_1) = P(x_2) = P(x_3) = \frac{1}{4}$$

قال Entropy هتكون Max

يعني إنت اعرف هيطلع ايه ال Average Uncertainty عالبت

$$H = \sum_i -P(x_i) \log_2(P(x_i))$$

$$= -\left[\frac{1}{4} * \log_2\left(\frac{1}{4}\right)\right] * 4$$

$$= 2 \text{ bits/symbol}$$

Average Number of bits needed to represent The Source

عشان كان uniform

قيمة ال $H = \log_2(N)$ ← عدد ال states بتاعت ال RV

(22) دى ال Max Entropy لل RV ده ، لكن

لو كان مثلاً ←

$X = \{0, 1, 2, 3\}$

$P = 0.8$ $P = 0.1$ $P = 0.05$ $P = 0.05$

ال Entropy هتطلع أقل ، لأن ال Uncertainty أقل ، لكنى عارف بنسبة كبيرة إنه هيطلع 0 ، فعدد ال bits اللى محتاج ابعته لل Rx عشان يعرف إنه هيطلع 0 ال RV و ٨ ٨ هيكون قليل ←

$$H = -\left[0.8 * +\log_2(0.8) + 0.1 * \log_2(0.05) + 0.05 \log_2(0.05) + 0.05 \log_2(0.05)\right]$$

$$H = 1.02 \text{ bits}$$

(23)

ال Entropy هتكون بقى اللى Min

هو 0 ، و لو كانت ال case كده

$X = \{0, 1, 2, 3\}$

$P=1 \quad P=0 \quad P=0 \quad P=0$

$$H = -\left[1 * \log_2(1) + 0 \log_2(0) * 3\right]$$

$$H = 0$$

وده منطقى مش محتاج ابعت لل bits لأنه R_X Zero Info, Zero surprise

كده كده ال R_X عارف إن ال X هيطلع بـ 0 .

فيقول لـ (x_i) one symbol

$$I(x_i) = -\log_2(P(x_i))$$

$$H(x_i) = P(x_i) * -\log_2(P(x_i))$$

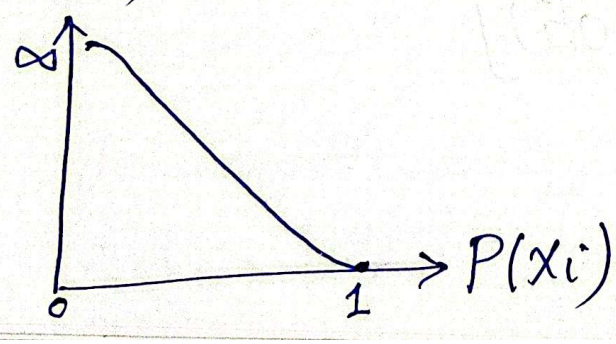

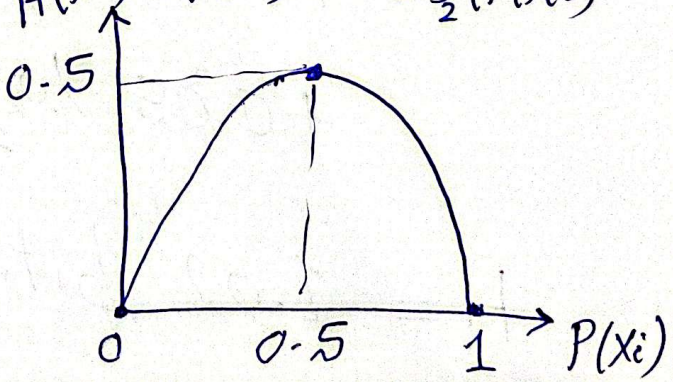

لو عندي بقى Two RVs بتعرف X, Y

حاجة اسمها ال Joint Entropy

$H(X,Y)$

ال definition بتاعها ←

$$H(X,Y) = \sum_x \sum_y -P(x,y) \log_2 (P(x,Y))$$

↓ Joint Probability

طب ايه علاقة ال $H(X,Y)$ بال $H(X)$ و $H(Y)$

ال $H(X)$ بتمثل ال Info اللى موجودة فال X و ال $H(Y)$ بتمثل ال Info اللى موجودة فال Y.

ال $H(X,Y)$ بتمثل ال Info اللى موجودة فال X,Y مع بعض ، لو كانوا Independant فال Info اللى فيهم الاثنين هيكون المجموع

$$H(X,Y) = H(X) + H(Y)$$

If (X,Y) are Independant

وممكن نثبتها من ال MaTh يعني

$$P(X,Y) = P(X)\,P(Y) \quad , \quad X,Y \text{ are Ind.}$$

$$H(X,Y) = \sum_x \sum_y -P(X)P(Y)\log_2(P(X)P(Y))$$

$$= -\sum_x P(X)\log_2(X) - \sum_y P(Y)\log_2(Y)$$

$$= H(X) + H(Y)$$

لكن لو X,Y كانوا dePendant

ساعتها معرفتي بال Info اللي فال X

هتقلل ال Info اللي محتاجها في ال Y

يعني إن دلوقتي لو ال X بيعبر عن

درجة الحرارة ، وال Y بيعبر عن الشهور

فدلوقتي ال Rx مثلاً ال Info اللي محتاجها

علشان يعرف درجة الحرارة ، هتقلل من عدد
ال Info اللى هيحتاجها علشان يعرف احنا
فى شهر ايه .

يعنى لو قولتلك هتعرف احنا فى شهر
ايه من غير ماقوله درجة الحرارة ، هيحتاج
Info أكتر علشان يعرف ، لكن لو عرف
إننا فى درجة الحرارة مثلاً 15°
فكده عدد ال Info علشان يعرف احنا
فى شهر كام هتكون أقل ، كده
خلاص هيبور فى شهور الشتا بعكس
الأول كان هيبور فى كل شهور السنة
وبالتالى لو X, Y
dependant

يبقى مقدار ال Info فال X, Y يعنى
ال Info اللى هحتاجها علشان اعرف
X, Y هتكون أقل من إنى اعرف X
لوحده و Y لوحده يعنى

$$H(X,Y) < H(X) + H(Y)$$

In General ← يبقى

$$H(X,Y) \leq H(X) + H(Y)$$

بتعرف كمان ← Conditional Entropy

$H(X|Y)$ ←

فعندنا الأول ←

عايز احسب ال H بتاع ال X بمعلومية ← إن Y = y (value) محددة

$$H(X|Y=y) = \sum_{x} -P(x_i|Y=y) \log_2 \left(P(x_i|Y=y)\right)$$

طب لو عايز اجيب بقى ← $H(X|Y)$

فهعمل Average على ال y.

(28)

$$H(X|Y) = \sum_y P(y_i) \cdot \sum_x - P(x_i|Y=y_i) * \log_2 (P(x_i)Y=y_i)$$

$$= \sum_x \sum_y - \boxed{P(y_i) P(x_i|Y=y_i)} * \log_2 (P(x_i|Y=y_i))$$

$$P(x_i, y_i)$$

$$H(X|Y) = \sum_x \sum_y - P(x,y) \log_2 (P(X|Y))$$

$$H(Y|X) = \sum_x \sum_y - P(x,y) \log_2 (P(y|x))$$

ال Conditional دی بقی بتعبر عنه ایه

فبال MaTh ممکن نوصلها لکده ؟!

$$H(X|Y) = H(X,Y) - H(Y)$$

$$H(Y|X) = H(X,Y) - H(X)$$

اللی هو ممکن نکتب کده

$$\boxed{H(X,Y) = H(Y) + H(X|Y)}$$

$$H(X,Y) = H(X) + H(Y|X)$$

معنى الكلام ده إني عشان اعرف

ال Info اللى فى ال $X, Y \rightarrow H(X,Y)$

يبقى محتاج اعرف ال Info اللى فى

ال X مجموع عليها ال Info اللى فى

ال Y لما عرفت ال X.

أو العكس اعرف ال Info اللى فى ال

Y مجموع عليها ال Info اللى فى

ال X لما عرفت ال Y.

وده منطقى متماشى مع مثال درجة الحرارة

والشهور اللى قولناه - فى diagram

بقى بيلخص ال relations دى اسمه

"Venn Diagram"

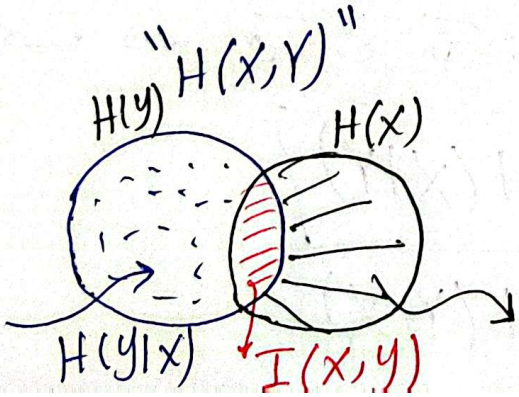

$$H(X,Y) = H(X) + H(Y|X)$$
$$H(X,Y) = H(Y) + H(X|Y)$$

الـ Intersection ده بنسميه ← Mutual Information ($I(X,Y)$)

ده بيقولنا ايه بقى ؟!

معرفتك بالـ Y هتعرفك قد ايه عن الـ X ، يعنى ايه الكلام ده

دلوقتى لو قولت $H(X) = 10$ bits

معناها إن الـ R_X محتاج لـ 10 bits عشان يعرف الـ X ايه ، بعد ما استلم الـ Y عند الـ R_X فال Uncertainty بتقل لو كان الـ X, Y ← يعنى dependant

$$H(X|Y) < H(X)$$

معرفتى بالـ Y قللت الـ uncertainty عن معرفتى بالـ X ، فلو قولنا ←

$$H(X|Y) = 5 \text{ bits}$$

فبنقول إن ←

$$I(X,Y) = H(X) - H(X|Y)$$

$$I(X,Y) = 5 \text{ bits}$$ يعني

فانا كان ال X عايز represent بـ 10 bits فعندي ←

1024 احتمال

بعد ماستلمت ال Y قللت الاحتمالات

لـ $2^5 \Rightarrow$ 32 احتمال

انا نفسي يكون عندي احتمال واحد عشان ال Rx يعمل decode من غير errors يعني كان نفسي ←

$$I(X,Y) = 10 \text{ bits}$$

يعني انا كده عند ال Y هقدر اعرف عن ال X ال 10 bits لو 5 هعرف 5 بس

وهكذا ، وعشان كده ممكن نعرف إن

ال Capacity كنا قولنا إنه عدد ال

bits اللى اقدر ابعته على ال

Channel بـ Zero Errors.

فاحنا بنقول من شويه اللى هقدر اعرفه

عدد ال X من ال Y هو ال I

فلو $I=10$ عايز $H(X)=10$ فلو

$I=20$ عايز $H(X)=20$ عشان

اقدر اعمل decode من غير errors

وبالتالى لما ممكن اقول إن عدد ال

bits اللى اقدر ابعته هو $I(X,Y)$

$$C = I(X,Y)$$

ولما عايز ال C دى تكون ال Max

فانا عايز ال Max بتاع ال $I(X,Y)$

$$C = \max(I(X,Y))$$

فانا علشان ابعت، أو احقق احسن

Maximize محتاج اعمل Capacity

لـ $I(X,Y)$

وده هيكون معتمد إني ابعت الـ X

Probabilitys بأنهي.

فانا علشان اشوف الـ $P(X)$ اللي بت

Maximize الـ $I(X,Y)$

هعمل diff. بالنسبة لـ $P(X)$

$$\frac{dI(X,Y)}{dP(X)} = 0 \Longrightarrow$$

get $P(X)$

That Maximize

$I(X,Y)$